

# SAP Projekt

Statistički Analizirani

2025-12-10

## Motivacija i opis problema

Moždani udar je hitno medicinsko stanje koje nastaje nakon poremećaja cirkulacije u mozgu. U Hrvatskoj je drugi najveći uzrok smrti te prvi najveći uzrok invaliditeta. Rizik od moždanog udara kod pojedine osobe može ovisiti o više faktora pa se u medicini koriste razni modeli za njegovu procjenu. Nije strana ni uporaba alata zasnovanih na umjernoj inteligenciji. Predikcija moždanog udara bitna je za pravovremenu identifikaciju rizika koje omogućava pravovremene mјere prevencije i osvještavanje populacije.

## Opis skupa podataka

Prikupljeni skup podataka sadrži kliničke podatke o pacijentima i informacije o moždanom udaru. Za svakog pacijenta navedena je vrijednost 12 značajki grupiranih u 4 kategorije: demografski podaci, zdravstveni podaci, fiziološki podaci i životne navike. Cilj je uočiti povezanost izmјerenih podataka i rizika od moždanog udara. Skup podataka sadržava 5,110 zapisa o pacijentima od kojih je njih 249 doživjelo moždani udar. Udio pacijenata koji su doživjeli moždani udar iznosi 4.87%

- id: jedinstveni identifikator pacijenta
- gender: spol pacijenta (Male, Female)
- age: dob pacijenta
- hypertension: oznaka koja daje informaciju o tome ima li pacijent visoki tlak (0, 1)
- heart\_disease: oznaka koja daje informaciju ima li pacijent neku srčanu bolest (0, 1)
- ever\_married: odgovara na pitanje je li pacijent ikad bio u braku (No, Yes) work\_type: tip zaposlenja (children, Govt\_job, Never\_worked, Private, Self-employed)
- Residence\_type: tip prebivališta u kojem živi pacijent (Rural, Urban)
- avg\_glucose\_lvl: prosječna razina glukoze u krvi (mg/dL)
- bmi: indeks tjelesne mase koji predstavlja odnos visine i težine pacijenta
- smoking\_status: opis pacijentovog odnosa s pušenjem cigareta (formerly smoked, never smoked, smokes, Unknown)
- stroke: oznaka koja daje informaciju je li pacijent doživio moždani udar (0, 1)

## Učitavanje i pregled podataka

```
data <- read.csv("data.csv")
head(data)
```

```
##      id gender age hypertension heart_disease ever_married    work_type
## 1  9046   Male  67              0             1        Yes      Private
## 2 51676 Female  61              0             0        Yes Self-employed
## 3 31112   Male  80              0             1        Yes      Private
```

```

## 4 60182 Female 49          0          0      Yes      Private
## 5 1665 Female 79          1          0      Yes Self-employed
## 6 56669  Male 81          0          0      Yes      Private
##   Residence_type avg_glucose_level bmi  smoking_status stroke
## 1       Urban           228.69 36.6 formerly smoked     1
## 2      Rural            202.21 N/A    never smoked     1
## 3      Rural            105.92 32.5    never smoked     1
## 4      Urban            171.23 34.4      smokes     1
## 5      Rural            174.12   24    never smoked     1
## 6      Urban            186.21   29 formerly smoked     1

str(data)

## 'data.frame': 5110 obs. of 12 variables:
## $ id          : int 9046 51676 31112 60182 1665 56669 53882 10434 27419 60491 ...
## $ gender      : chr "Male" "Female" "Male" "Female" ...
## $ age         : num 67 61 80 49 79 81 74 69 59 78 ...
## $ hypertension: int 0 0 0 0 1 0 1 0 0 0 ...
## $ heart_disease: int 1 0 1 0 0 0 1 0 0 0 ...
## $ ever_married: chr "Yes" "Yes" "Yes" "Yes" ...
## $ work_type   : chr "Private" "Self-employed" "Private" "Private" ...
## $ Residence_type: chr "Urban" "Rural" "Rural" "Urban" ...
## $ avg_glucose_level: num 229 202 106 171 174 ...
## $ bmi         : chr "36.6" "N/A" "32.5" "34.4" ...
## $ smoking_status: chr "formerly smoked" "never smoked" "never smoked" "smokes" ...
## $ stroke      : int 1 1 1 1 1 1 1 1 1 1 ...

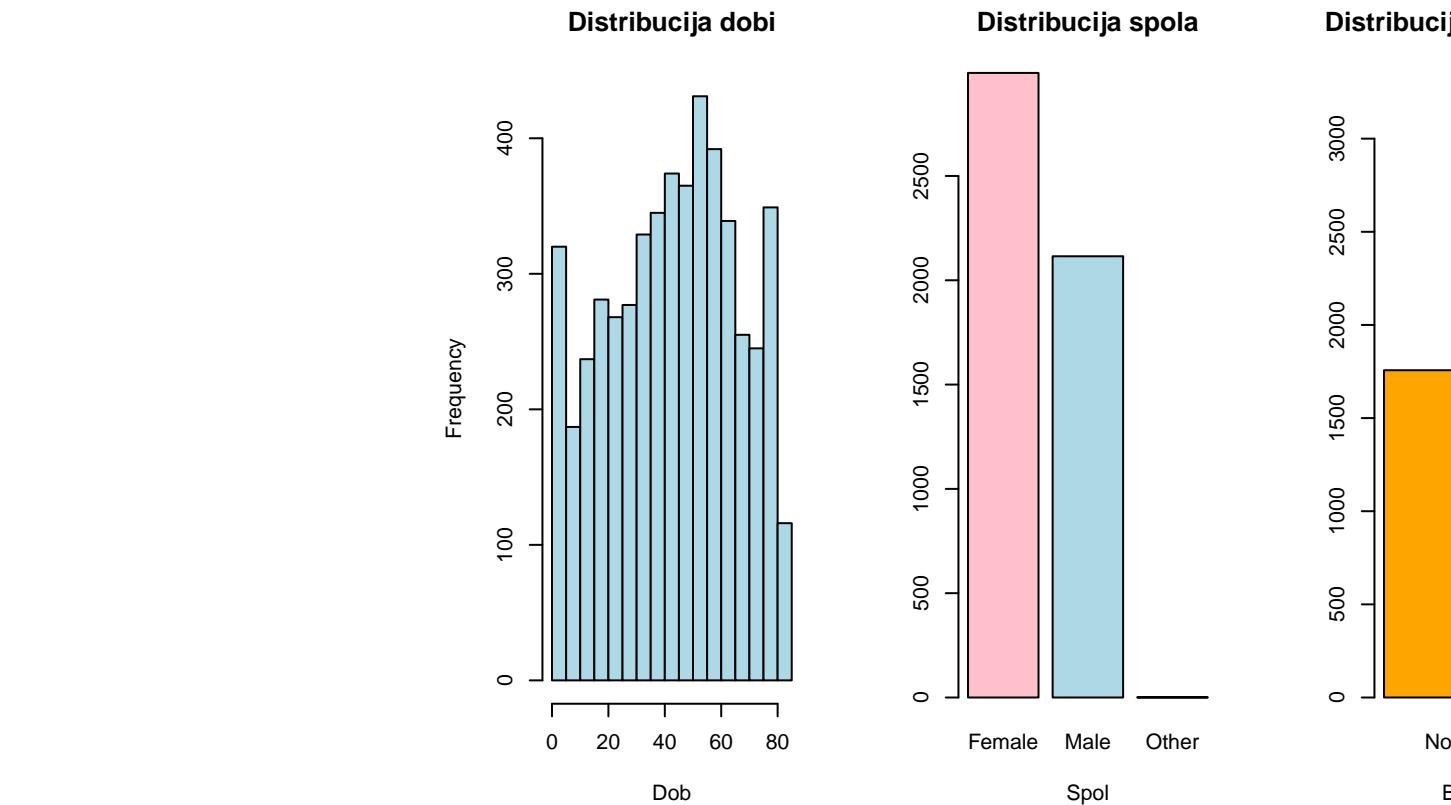
```

Iz generiranih prikaza moguće je vidjeti neke od vrijednosti koje poprimaju pojedini atributi vezani uz pacijenta, ali i tip podataka koji prikazuju. Primjetljivo je kako se atribut bmi vodi kao niz znakova iako semantički predstavlja decimalni broj. Pri izradi dijagrama i u budućim računima potrebno je pripaziti da se bmi ne prikaže kao kategorični atribut.

```

par(mfrow = c(1,3))
hist(data$age , main = "Distribucija dobi", xlab = "Dob", col = "lightblue", border = "black")
barplot(table(data$gender), main = "Distribucija spola", xlab = "Spol", col = c("pink","lightblue","black"))
barplot(table(data$ever_married), main = "Distribucija bracnog statusa", xlab = "Bracni status", col = c("pink","lightblue","black"))

```



Prikaz demografskih podataka

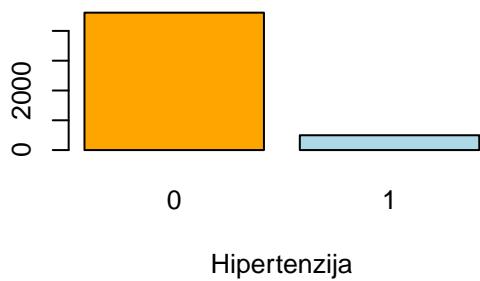
**Prikaz zdravstvenih podataka** Kao što je prethodno navedeno, potrebno je pripremiti atribut bmi.

```
bmi<-data$bmi

bmi[bmi == "N/A"] <- NA
bmi <- as.numeric(bmi)

par(mfrow = c(2,2))
barplot(table(data$hypertension), main = "Distribucija hipertenzije", xlab = "Hipertenzija", col = c("orange","lightblue"))
barplot(table(data$heart_disease), main = "Distribucija srcanih bolesti", xlab = "Srcane bolesti", col = c("orange","lightblue"))
hist(data$avg_glucose_level , main = "Distribucija kolicine glukoze u krvi", xlab = "Kolicina glukoze u krvi", col = "lightblue")
hist(bmi , main = "Distribucija indeksa BMI", xlab = "BMI", col = "lightblue", border = "black")
```

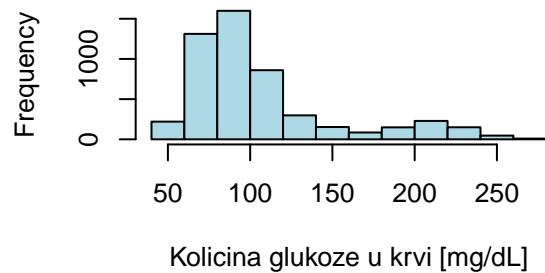
### Distribucija hipertenzije



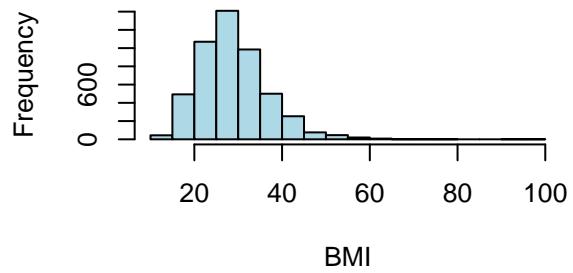
### Distribucija srcanih bolesti



### Distribucija kolicine glukoze u krvi

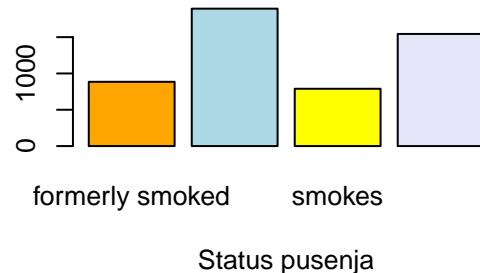


### Distribucija indeksa BMI

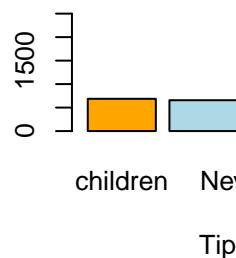


```
par(mfrow = c(2,2))
barplot(table(data$smoking_status), main = "Distribucija statusa pusenja", xlab = "Status pusenja", col = c("orange", "lightblue"))
barplot(table(data$work_type), main = "Distribucija tipa zaposlenja", xlab = "Tip zaposlenja", col = c("orange", "lightblue"))
barplot(table(data$Residence_type), main = "Distribucija tipa prebivališta", xlab = "Tip prebivališta", col = c("orange", "lightblue"))
```

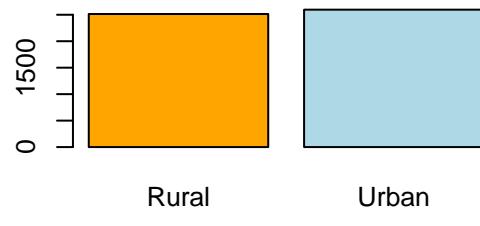
Distribucija statusa pusenja



Distribucija



Distribucija tipa prebivali.ta



### Prikaz podataka o životnim navikama

Postoji li statistički značajna razlika u prosječnoj razini glukoze između pacijenata sa i bez moždanog udara?

```
data_stroke <- data[data$stroke == 1, ]$avg_glucose_level
data_no_stroke <- data[data$stroke == 0, ]$avg_glucose_level
summary(data_stroke)

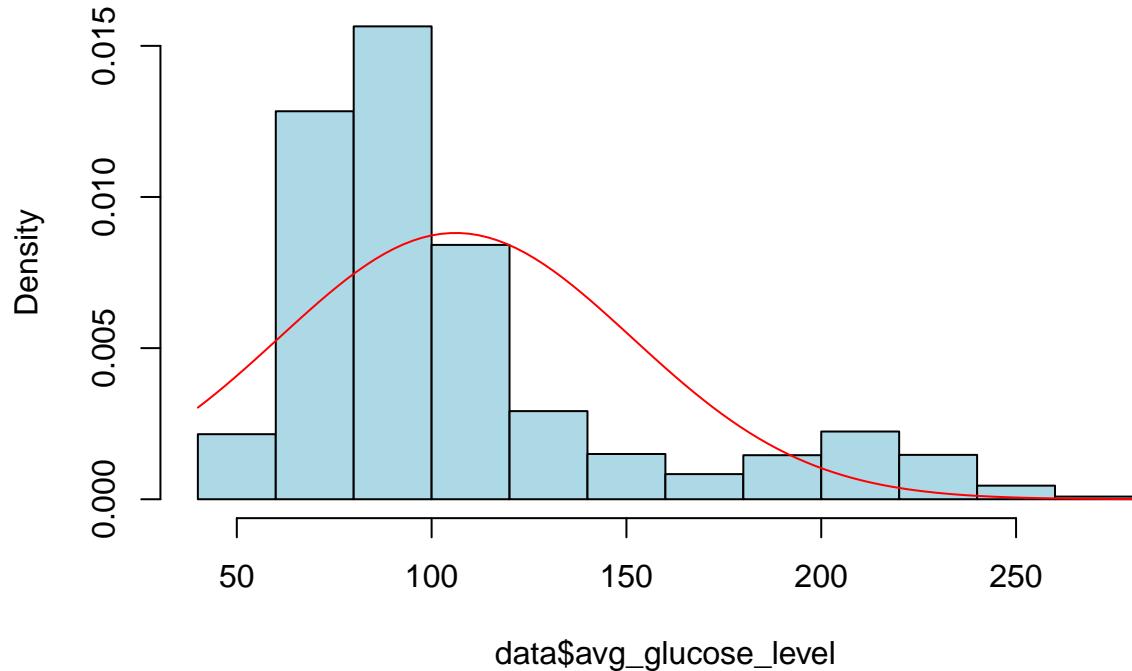
##      Min. 1st Qu. Median      Mean 3rd Qu.      Max.
##    56.11   79.79 105.22 132.54 196.71 271.74

summary(data_no_stroke)

##      Min. 1st Qu. Median      Mean 3rd Qu.      Max.
##    55.12   77.12  91.47 104.80 112.83 267.76

hist(data$avg_glucose_level, freq = FALSE, col = "lightblue", border = "black")
curve(dnorm(x, mean(data$avg_glucose_level), sd(data$avg_glucose_level)), add = TRUE, col = "red")
```

## Histogram of data\$avg\_glucose\_level



```
set.seed(67)

B <- 10000

boot_diff <- numeric(B)

for (i in 1:B) {
  boot_data_stroke <- sample(data_stroke, replace = TRUE)
  boot_data_no_stroke <- sample(data_no_stroke, replace = TRUE)
  boot_diff[i] <- mean(boot_data_stroke) - mean(boot_data_no_stroke)
}

# Observed mean difference
obs_diff <- mean(data_stroke) - mean(data_no_stroke)

# 95% bootstrap confidence interval
ci <- quantile(boot_diff, c(0.025, 0.975))

list(
  observed_mean_difference = obs_diff,
  ci_95 = ci
)

## $observed_mean_difference
## [1] 27.74923
##
```

```

## $ci_95
##      2.5%    97.5%
## 19.94809 35.74191

head(data)

##      id gender age hypertension heart_disease ever_married      work_type
## 1 9046   Male  67            0            1        Yes     Private
## 2 51676 Female  61            0            0        Yes Self-employed
## 3 31112   Male  80            0            1        Yes     Private
## 4 60182 Female  49            0            0        Yes     Private
## 5 1665 Female  79            1            0        Yes Self-employed
## 6 56669   Male  81            0            0        Yes     Private
##      Residence_type avg_glucose_level bmi smoking_status stroke
## 1           Urban          228.69 36.6 formerly smoked      1
## 2          Rural          202.21  N/A never smoked      1
## 3          Rural          105.92 32.5 never smoked      1
## 4           Urban          171.23 34.4      smokes      1
## 5          Rural          174.12   24 never smoked      1
## 6           Urban          186.21   29 formerly smoked      1

```

### Postoji li interakcijski učinak hipertenzije i srčanih bolesti na BMI?

U ovom istraživačkom pitanju proučavamo ovisi li indeks tjelesne mase (BMI) o prisutnosti hipertenzije i srčanih bolesti te postoji li interakcijski učinak ova dva čimbenika. Dakle, zanima nas utječe li hipertenzija na BMI jednako kod osoba sa i bez srčanih bolesti ili se taj učinak mijenja ovisno o postojanju srčane bolesti. Za potrebe analize koristimo dvostruku analizu varijance s hipertenzijom i srčanim bolestima kao čimbenicima te BMI-jem kao zavisnom varijablom.

### Priprema podataka

Najprije pripremamo podatke. Brišemo nedostajuće vrijednosti BMI-ja, pretvaramo BMI u numeričku varijablu te kodiramo hipertenziju i srčane bolesti kao faktore s dvije razine.

```

data2 <- read.csv("data.csv", na.strings = "N/A", stringsAsFactors = FALSE)

data2$hypertension <- factor(data2$hypertension, levels = c(0,1), labels = c("no_hypertension","has_hyp")
data2$heart_disease <- factor(data2$heart_disease, levels = c(0,1), labels = c("no_heart_disease","has_hd"))

data2$bmi <- as.numeric(data$bmi)

## Warning: NAs introduced by coercion

anova_data <- data2[, c("bmi", "hypertension", "heart_disease")]

anova_data <- na.omit(anova_data)

str(anova_data$bmi)

```

```

##  num [1:4909] 36.6 32.5 34.4 24 29 27.4 22.8 24.2 29.7 36.8 ...
summary(anova_data$bmi)

##      Min. 1st Qu. Median     Mean 3rd Qu.    Max.
## 10.30   23.50  28.10  28.89  33.10  97.60

table(anova_data$hypertension, anova_data$heart_disease)

##
##                                no_heart_disease has_heart_disease
## no_hypertension                  4273                  185
## has_hypertension                  393                   58

```

Broj opažanja nakon izbacivanja nedostajućih vrijednosti daje nam efektivnu veličinu uzorka za ovu analizu.

Ukupno je u analizi sudjelovalo 4 909 ispitanika.

Raspodjela prema prisutnosti hipertenzije i srčane bolesti je sljedeća:

- nema hipertenziju, nema srčanu bolest: **87.0 %**
- nema hipertenziju, ima srčanu bolest: **3.8 %**
- ima hipertenziju, nema srčanu bolest: **8.0 %**
- ima hipertenziju, ima srčanu bolest: **1.2 %**

Promatramo li postotke unutar razina hipertenzije:

- među osobama **bez hipertenzije**:
  - 95.9 % **nema** srčanu bolest
  - 4.1 % **ima** srčanu bolest
- među osobama **s hipertenzijom**:
  - 87.1 % **nema** srčanu bolest
  - 12.9 % **ima** srčanu bolest

Promatramo li postotke unutar razina srčane bolesti:

- među osobama **bez srčane bolesti**:
  - 91.6 % **nema** hipertenziju
  - 8.4 % **ima** hipertenziju
- među osobama **sa srčanom bolešću**:
  - 76.1 % **nema** hipertenziju
  - 23.9 % **ima** hipertenziju

```
head(anova_data)
```

```

##   bmi      hypertension      heart_disease
## 1 36.6  no_hypertension has_heart_disease
## 3 32.5  no_hypertension has_heart_disease
## 4 34.4  no_hypertension  no_heart_disease
## 5 24.0  has_hypertension  no_heart_disease
## 6 29.0  no_hypertension  no_heart_disease
## 7 27.4  has_hypertension has_heart_disease

```

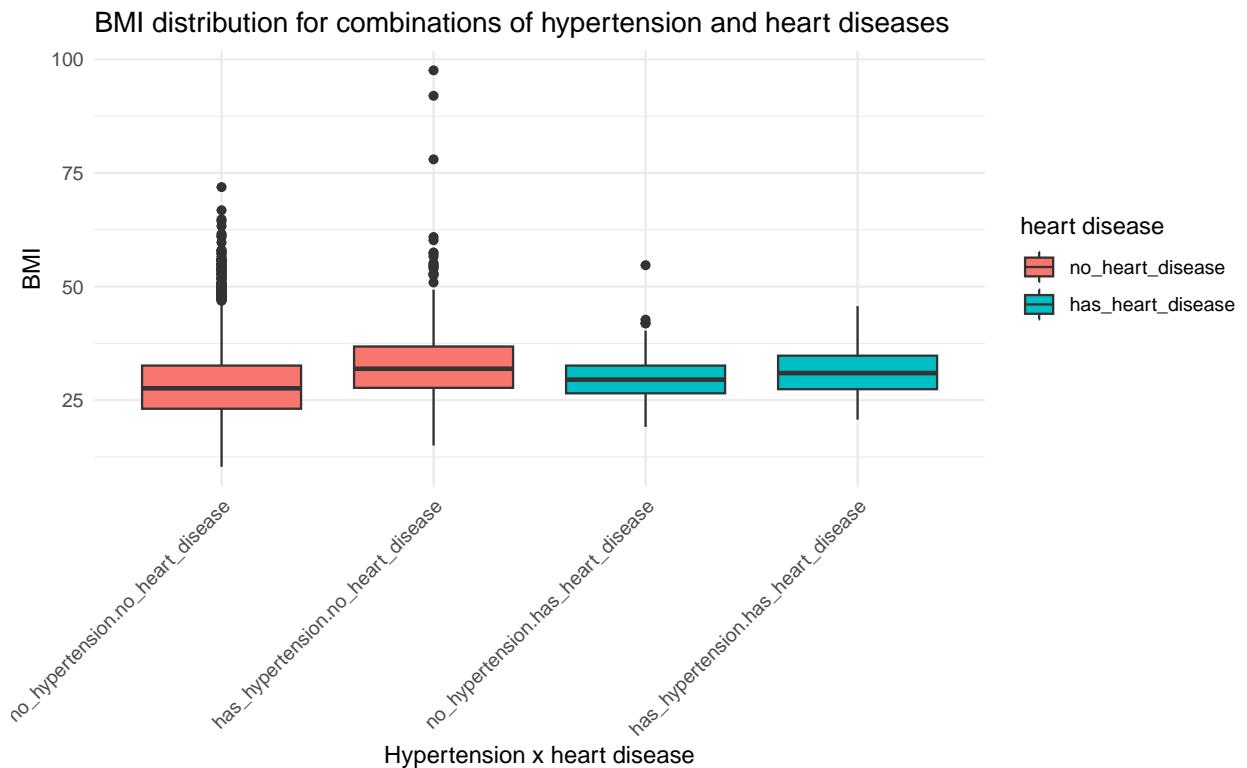
## Sredine po grupama (da znaš što zapravo znači rezultat)

Najprije izračunavamo prosječne vrijednosti BMI-ja po svakoj kombinaciji hipertenzije i srčane bolesti te ih vizualiziramo.

```
aggregate(bmi ~ hypertension + heart_disease,
          data = anova_data,
          FUN = mean)

##           hypertension   heart_disease      bmi
## 1    no_hypertension  no_heart_disease 28.40875
## 2   has_hypertension  no_heart_disease 33.28092
## 3   no_hypertension has_heart_disease 29.98270
## 4  has_hypertension has_heart_disease 31.38103

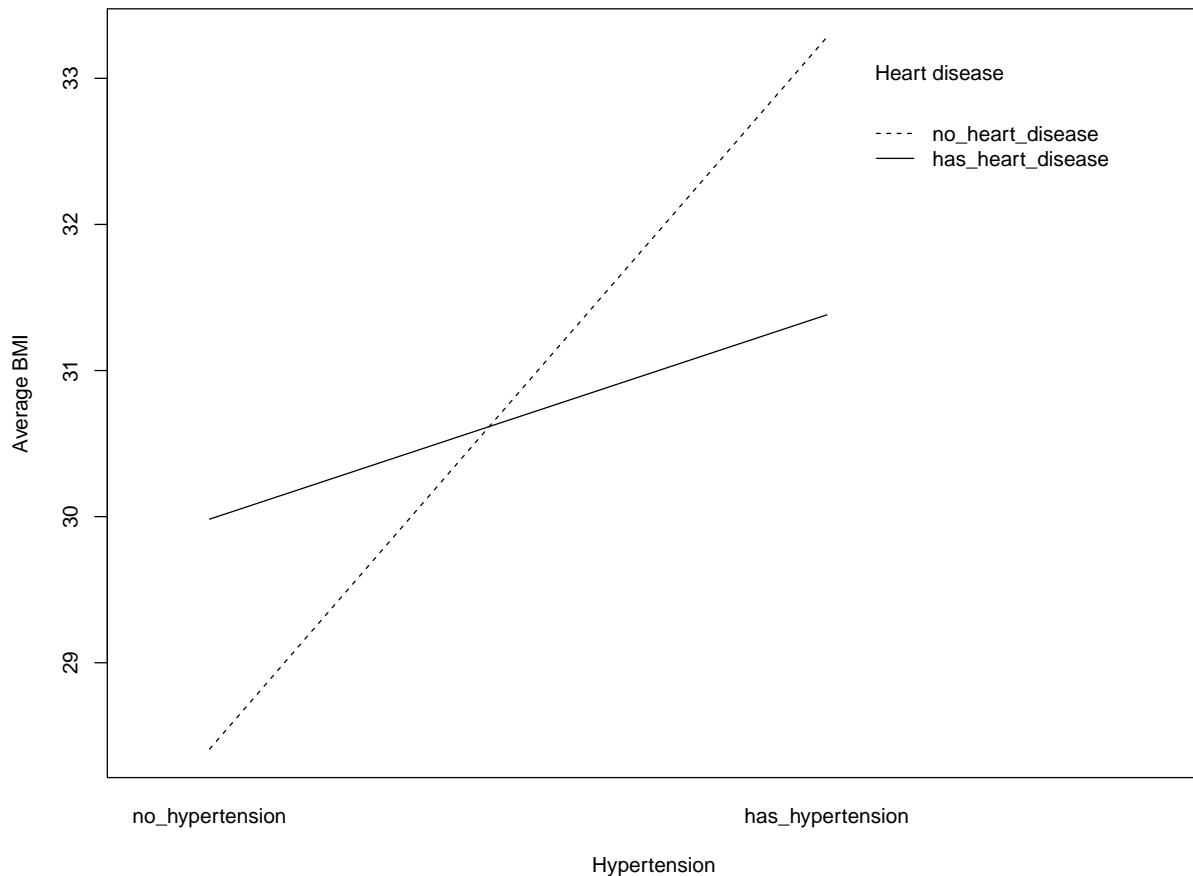
ggplot(anova_data,
       aes(x = interaction(hypertension, heart_disease),
            y = bmi,
            fill = heart_disease)) +
  geom_boxplot() +
  labs(x = "Hypertension x heart disease",
       y = "BMI",
       fill = "heart disease",
       title = "BMI distribution for combinations of hypertension and heart diseases") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



```

with(anova_data,
     interaction.plot(hypertension, heart_disease, bmi,
                       fun = mean,
                       xlab = "Hypertension",
                       ylab = "Average BMI",
                       trace.label = "Heart disease"))

```



Iz tablice sredina i grafova vidimo kako se prosječni BMI razlikuje između grupa. Zbog toga nas zanima mijenja li se razlika u BMI-ju između osoba s i bez hipertenzije ovisno o tome imaju li srčanu bolest, što je indikacija mogućeg interakcijskog učinka.

## Dvostruka ANOVA s interakcijom: formulacija hipoteza i primjena testa

Glavni učinak hipertenzije:

- H<sub>0</sub>: prosječni BMI je jednak kod osoba sa i bez hipertenzije
- H<sub>1</sub>: prosječni BMI se razlikuje između osoba sa i bez hipertenzije

Glavni učinak srčanih bolesti:

- H0: prosječni BMI je jednak kod osoba sa i bez srčane bolesti
- H1: prosječni BMI se razlikuje između osoba sa i bez srčane bolesti

Interakcijski učinak:

- H0: nema interakcijskog učinka hipertenzije i srčanih bolesti na BMI
- H1: postoji interakcijski učinak hipertenzije i srčanih bolesti na BMI

Za testiranje hipoteza koristimo dvostruku ANOVA-u s interakcijom:

```
test_anova <- aov(bmi ~ hypertension * heart_disease, data = anova_data)
summary(test_anova)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)							
## hypertension	1	8526	8526	142.430	< 2e-16 ***							
## heart_disease	1	147	147	2.457	0.11705							
## hypertension:heart_disease	1	475	475	7.929	0.00488 **							
## Residuals	4905	293609	60									
## ---												
## Signif. codes:	0	'***'	0.001	'**'	0.01	'*'	0.05	'.'	0.1	'	'	1

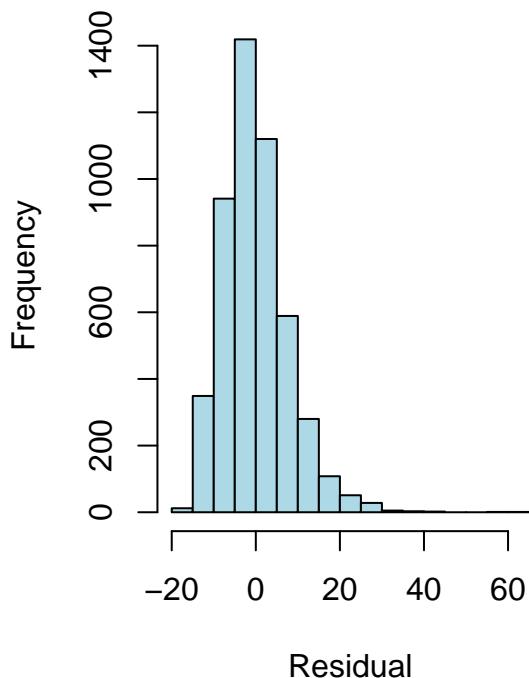
## Provjera prepostavki

Analiza varijance prepostavlja približnu normalnost reziduala i sličnost varijanci između grupa.

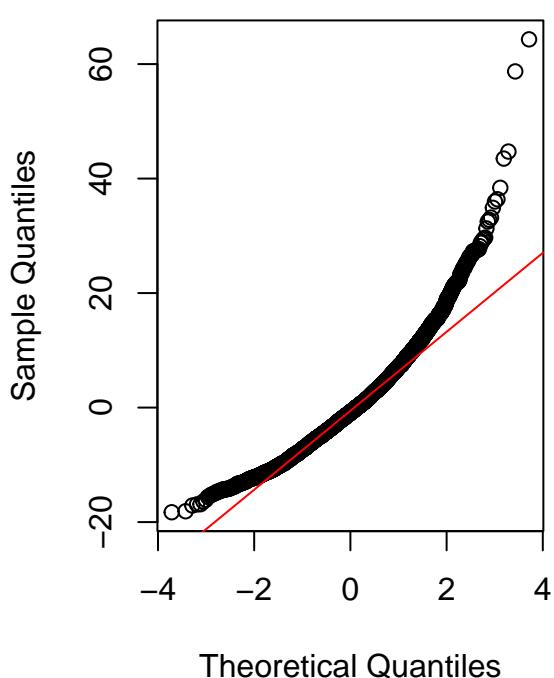
```
rezid <- residuals(test_anova)

par(mfrow = c(1, 2))
hist(rezid, main = "Residual histogram", xlab = "Residual", col = "lightblue", border = "black")
qqnorm(rezid, main = "QQ residual graf")
qqline(rezid, col = "red")
```

**Residual histogram**



**QQ residual graf**



```
par(mfrow = c(1, 1))
```

Reziduali pokazuju određena odstupanja, no zbog velikog uzorka ANOVA je relativno robustna na takva odstupanja.

## Rezultati i interpretacija

Na temelju ANOVA tablice zaključujemo sljedeće:

- Glavni učinak hipertenzije na BMI je statistički značajan (F vrijednost je vrlo velika,  $p < 0.001$ ), zbog čega možemo zaključiti da osobe s hipertenzijom u prosjeku imaju viši BMI od osoba bez hipertenzije.
- Glavni učinak srčanih bolesti na BMI nije statistički značajan ( $p$ -vrijednost je veća od 0.05), pa na ovoj razini značajnosti zaključujemo da prosječni BMI razlikuje između osoba sa i bez srčane bolesti kada se ostali čimbenici ne uzimaju u obzir.
- Interakcijski učinak hipertenzije i srčanih bolesti na BMI je statistički značajan ( $p < 0.01$ ), zbog čega zaključujemo da se učinak hipertenzije na BMI razlikuje ovisno o tome ima li osoba srčanu bolest.

Iz tablice prosječnih BMI vrijednosti po grupama vidimo da je najviši BMI tipično prisutan kod osoba koje imaju i hipertenziju i srčanu bolest, dok je najniži BMI kod osoba koje nemaju ni hipertenziju ni srčanu bolest.

## Postoji li povezanost izmedu statusa pušenja i nastanka moždanog udara?

U analizi se ispituje postoji li povezanost između statusa pušenja i pojave moždanog udara. Prvo se varijable smoking\_status i stroke pretvaraju u faktore kako bi se moglo ispravno koristiti u kontingencijskoj tablici i Chi-kvadrat testu.

Zatim se formira kontingencijska tablica za tri kategorije pušenja (bez Unknown) kako bi se izbjegla izobličenja u rezultatima.

## Postotak moždanih udara po kategorijama pušenja

Kako bismo bolje razumjeli učestalost moždanog udara unutar svake skupine pušačkog statusa, izrađen je barplot koji prikazuje proporciju pacijenata s moždanim udarom u odnosu na ukupni broj osoba unutar svake kategorije pušenja.

Iz grafa se može jasno vidjeti u kojoj skupini je udio moždanih udara najveći, što dodatno nadopunjuje statistički rezultat Chi-kvadrat testa.

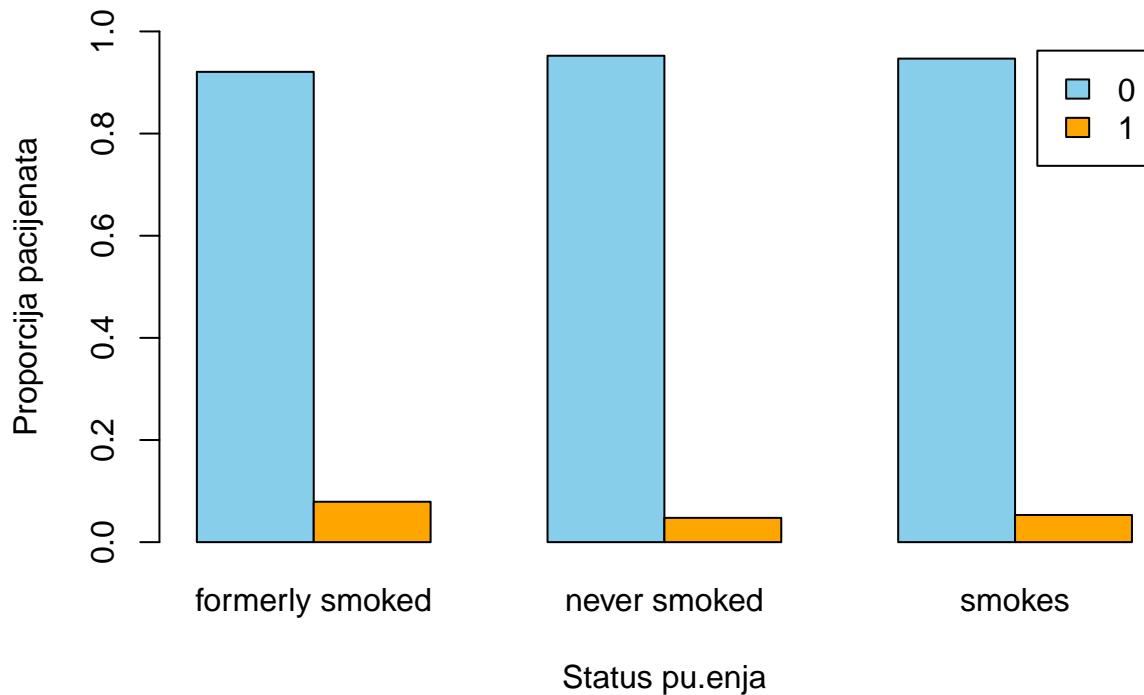
```
# Proporcije moždanih udara unutar svake kategorije pušenja
# Redovi: status pušenja, stupci: stroke (0/1)
data$smoking_status <- as.factor(data$smoking_status)
data$stroke <- as.factor(data$stroke)

tablica <- table(data$smoking_status, data$stroke)
tablica <- tablica[-4, ] # uklanjamo 'Unknown'

prop_tab <- prop.table(tablica, 1) # row-wise proportions

# Barplot - prikaz proporcija
barplot(t(prop_tab),
        beside = TRUE, # stupci jedan do drugog
        legend = TRUE, # legenda za stroke 0/1
        col = c("skyblue", "orange"), # boje za stroke 0 i 1
        main = "Postotak moždanih udara po kategorijama pušenja",
        xlab = "Status pušenja",
        ylab = "Proporcija pacijenata",
        ylim = c(0,1)) # proporcija od 0 do 1
```

## Postotak mođanih udara po kategorijama pujenja



### Chi-kvadrat test – osnovna tablica

U ovom dijelu analiziramo odnos između statusa pušenja i pojave moždanog udara. Nakon čišćenja podataka kreirana je kontingencijska tablica koja uključuje tri kategorije pušenja: never smoked, formerly smoked i smokes (kategorija Unknown je uklonjena).

Na temelju ove tablice proveden je Chi-kvadrat test neovisnosti kako bi se provjerilo postoji li statistički značajna povezanost između statusa pušenja i moždanog udara. Test vraća vrijednost statistike, stupnjeve slobode i p-vrijednost. Ako je p-vrijednost manja od 0.05, odbacujemo hipotezu o neovisnosti i zaključujemo da je status pušenja povezan s pojavom moždanog udara.

Uz to se pregledavaju i očekivane frekvencije kako bismo provjerili jesu li zadovoljeni uvjeti za ispravno provođenje Chi-kvadrat testa (svaka očekivana frekvencija  $> 5$ ). Ovaj test pruža osnovni uvid u to razlikuju li se skupine pušača u učestalosti moždanog udara.

Hipoteze:

- H0: Status pušenja nije povezan s pojavom moždanog udara (neovisne su varijable).
- H1: Status pušenja je povezan s pojavom moždanog udara (varijable nisu neovisne).

```
# Čišćenje: pretvaranje smoking_status u faktor
data$smoking_status <- as.factor(data$smoking_status)
data$stroke <- as.factor(data$stroke)
```

```
# Kontingencijska tablica
```

```
tablica <- table(data$smoking_status, data$stroke)
tablica <- tablica[-4, ]
tablica
```

```
##
##          0     1
## formerly smoked 815   70
## never smoked    1802  90
## smokes           747   42
```

```
# Chi-square test
chi_rezultat <- chisq.test(tablica)
chi_rezultat
```

```
##
## Pearson's Chi-squared test
##
## data: tablica
## X-squared = 11.436, df = 2, p-value = 0.003285
```

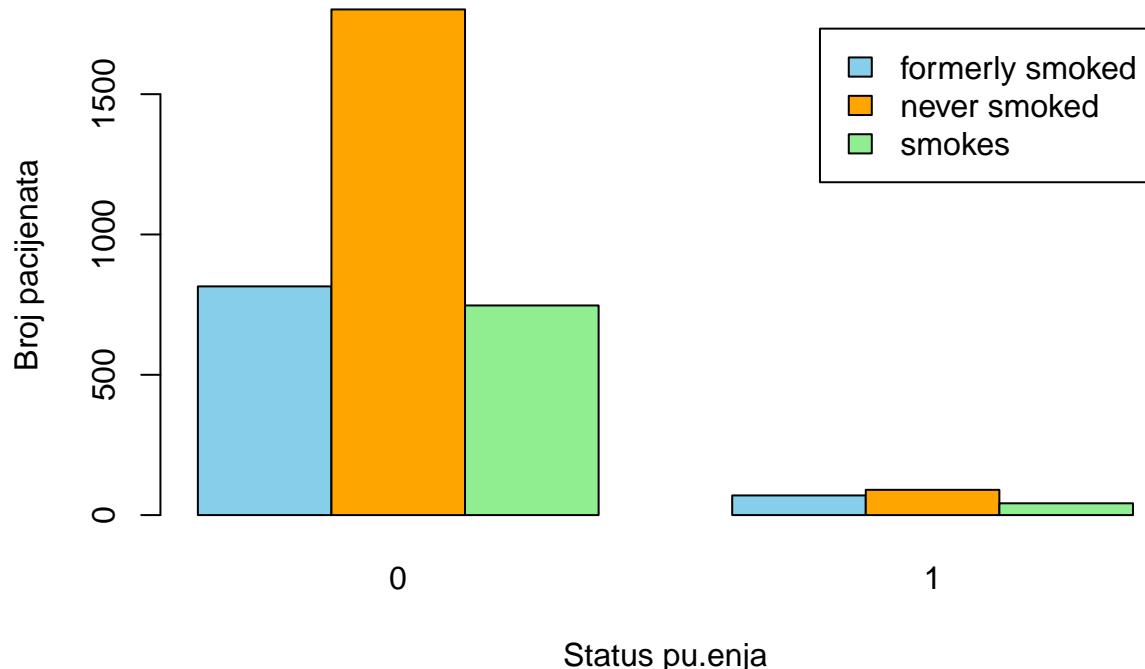
```
chi_rezultat$expected
```

```
##
##          0         1
## formerly smoked 834.8682 50.13180
## never smoked    1784.8256 107.17443
## smokes           744.3062 44.69377
```

U nastavku je prikazan barplot koji vizualno predstavlja povezanost između statusa pušenja i pojave moždanog udara. Svaka skupina pušačkog statusa (never smoked, formerly smoked, smokes) prikazana je s pripadnim brojem osoba koje su doživjele ili nisu doživjele moždani udar.

```
# Barplot - odnos pušenja i moždanog udara (osnovna tablica)
barplot(tablica,
        beside = TRUE,
        legend = TRUE,
        col = c("skyblue", "orange", "lightgreen"),
        main = "Povezanost pušenja i moždanog udara",
        xlab = "Status pušenja",
        ylab = "Broj pacijenata")
```

## Povezanost pu.enja i mo.danog udara



Kontingencijska tablica uključivala je tri kategorije pušenja: never smoked, formerly smoked i smokes. Chi-kvadrat test neovisnosti pokazao je p-vrijednost manju od 0.05, što znači da postoji statistički značajna povezanost između statusa pušenja i moždanog udara. Očekivane frekvencije su bile zadovoljavajuće ( $>5$ ), što potvrđuje valjanost testa.

### Spajanje kategorija – bivši i sadašnji pušači vs. nikad pušili

U drugom pristupu spajaju se kategorije formerly smoked i smokes u jednu zajedničku skupinu nazvanu „was smoking/smokes“. Time se formiraju dvije jasne skupine:

1. Osobe koje nikada nisu pušile (never smoked)
2. Osobe koje su pušile, bez obzira na to puše li trenutno ili su prestale (was smoking/smokes)

Ovakva podjela omogućuje ispitivanje temeljnog pitanja: Je li bilo kakva povijest pušenja povezana s pojavom moždanog udara?

Nakon formiranja nove tablice provodi se Chi-kvadrat test neovisnosti kako bi se provjerilo razlikuje li se učestalost moždanog udara između ove dvije skupine. Ako je dobivena p-vrijednost statistički značajna ( $p < 0.05$ ), zaključujemo da postoji povezanost između povijesti pušenja i rizika moždanog udara.

Uz test izrađen je i barplot koji grafički prikazuje raspodjelu moždanog udara u djelama skupinama. Vizualizacija dodatno olakšava uočavanje eventualnih razlika između osoba koje nikad nisu pušile i onih koje su pušile barem jednom u životu.

Hipoteze:

- H0: Povijest pušenja (nikad vs. ikad) nije povezana s pojavom moždanog udara.
- H1: Povijest pušenja (nikad vs. ikad) jest povezana s pojavom moždanog udara.

```
# Kreiranje nove tablice: spajamo kategorije 'formerly smoked' i 'smokes'
nova_tablica <- table(data$smoking_status, data$stroke)

# Uklanjamo kategoriju 'Unknown' jer nema korisne informacije
nova_tablica <- nova_tablica[-4, ]

# Spajamo redove: formerly smoked + smokes
# (to znači da gledamo osobe koje su ikada pušile - trenutno ili ranije)
nova_tablica[2,] <- nova_tablica[2, ] + nova_tablica[3, ]

# Brišemo sada već spojen treći red
nova_tablica <- nova_tablica[-3, ]

# Preimenujemo redove radi jasnijeg prikaza
rownames(nova_tablica)[1] <- "never smoked" # nikad nisu pušili
rownames(nova_tablica)[2] <- "was smoking/smokes" # ikad pušili (prije ili sada)

# Prikaz nove tablice nakon spajanja
nova_tablica
```

```
##  
##          0     1  
## never smoked    815    70  
## was smoking/smokes 2549   132
```

```
# Chi-kvadrat test za provjeru povezanosti između pušenja (nikad vs. ikad) i moždanog udara
# Ako je p-vrijednost < 0.05 → postoji statistička povezanost između pušenja i moždanog udara
chi_rezultat <- chisq.test(nova_tablica)
```

```
# Ispis rezultata testa
chi_rezultat
```

```
##  
## Pearson's Chi-squared test with Yates' continuity correction  
##  
## data: nova_tablica  
## X-squared = 10.551, df = 1, p-value = 0.001162
```

```
chi_rezultat$expected
```

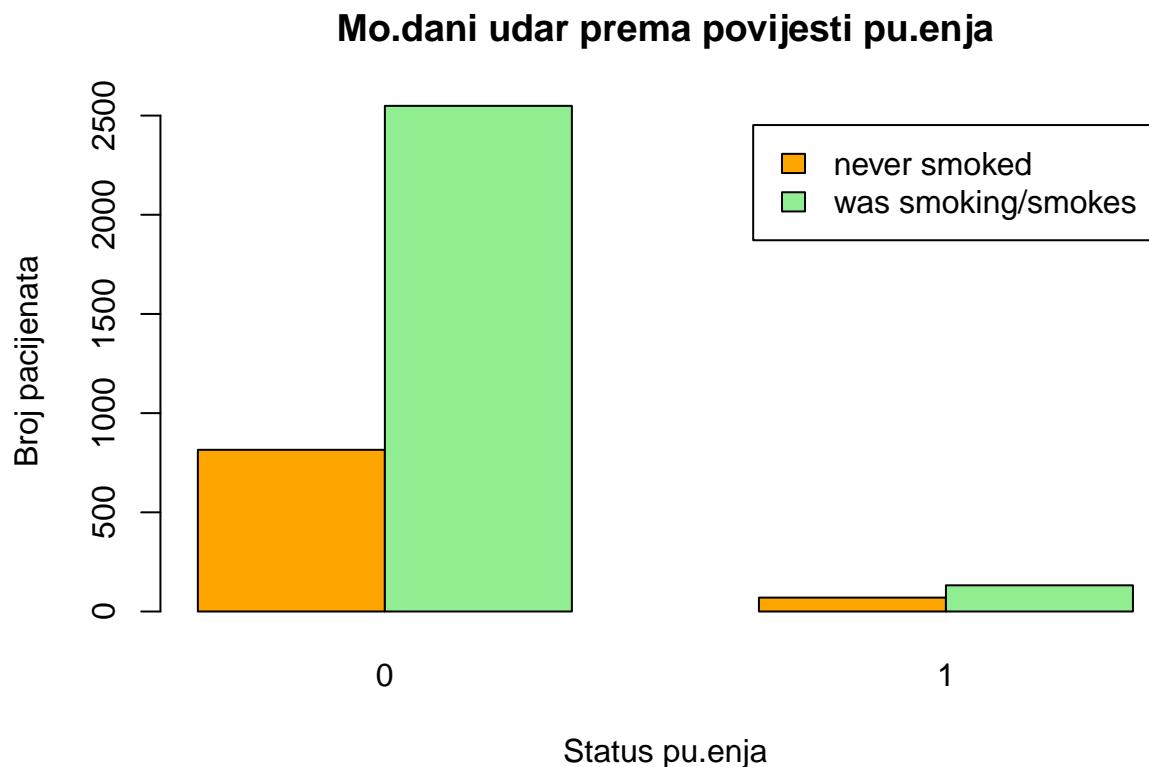
```
##  
##          0     1  
## never smoked    834.8682  50.1318  
## was smoking/smokes 2529.1318 151.8682
```

```
barplot(nova_tablica,
        beside = TRUE,
        legend = TRUE,
```

```

col = c("orange", "lightgreen"),
main = "Moždani udar prema povijesti pušenja",
xlab = "Status pušenja",
ylab = "Broj pacijenata")

```



Kombinirane su kategorije formerly smoked i smokes u jednu skupinu „was smoking/smokes“, a druga skupina su osobe koje nikada nisu pušile. Chi-kvadrat test na ovoj dvodijelnoj tablici također je dao p-vrijednost manju od 0.05, što potvrđuje statistički značajnu razliku u učestalosti moždanog udara između osoba koje nikada nisu pušile i onih koje su ikada pušile (trenutno ili prije).